uc3m
2025-26. APRENDIZAJE AUTOMÁTICO

PRIMERA PRÁCTICA: PREDICCIÓN DE SUBSCRIPCIÓN A UN PRODUCTO BANCARIO (3.5 PUNTOS)

ÍNDICE DE CONTENIDOS

Introducción 1
Consideraciones generales 1
Pasos a seguir 1
1. GITHUB (0,4 puntos) 1
2. EDA simplificado (0,3 puntos) 2
3. Decidir cómo se va a realizar la evaluación (0,1 PUNTOS) 2
4. Métodos básicos: KNN y TREES (1,0 puntos) 2
5. Métodos avanzados: modelos lineales y SVMs (0,6 puntos) 3
4. Resultados y modelo final (0,3 puntos) 3
5. Desplegar el modelo final usando Streamlit (0,4 puntos) 3
6. Tarea de elección abierta (0,4 puntos) 3
¿Qué entregar? 3
Apéndice: Descripción de las Variables 5

INTRODUCCIÓN

El propósito de esta primera práctica es practicar con diferentes métodos de aprendizaje automático. Además, se trata de tratar todo el proceso: determinar el mejor método para un conjunto de datos (**selección de modelo**, incluido el preproceso y el ajuste de hiperparámetros/HPO), estimar el rendimiento futuro del mejor método (**evaluación de modelo**) y **construir el modelo final** y usarlo para hacer nuevas predicciones sobre nuevos datos (**uso del modelo**).

El tema de este trabajo es predecir si un cliente bancario suscribirá un depósito a plazo. Un banco desea construir un modelo predictivo basado en datos demográficos, financieros y de interacción de los clientes, con el objetivo de identificar a aquellos con mayor probabilidad de aceptar el producto al ser contactados. La variable objetivo es **deposit**.

CONSIDERACIONES GENERALES

1. Los resultados **deben ser reproducibles**. Por lo tanto, hay que fijar la semilla (el NIA de uno de los miembros del grupo) en los lugares apropiados.

2. Se valorará presentar y analizar los resultados de **forma clara**, utilizando principalmente tablas para presentar múltiples resultados y comparar alternativas.

3. Caso de ser utilizada, será necesario explicar cómo se ha usado la IA generativa en esta práctica. Se pueden incluir prompts (y respuestas) relevantes, casos en los que la IA estaba equivocada, etc.

4. **El preprocesamiento** debe llevarse a cabo mediante **pipelines,** siempre que sea posible, y utilizando los pasos de preprocesamiento adecuados para cada uno de los métodos elegidos.

5. Cada grupo (de dos personas máximo) utilizará **dos ficheros**: "bank_xx.pkl" (en formato pickle) y "bank_competition_xx.pkl". xx = a + b, donde "ab" son los dos últimos dígitos del NIA de uno de los miembros del grupo. "bank_xx" contiene los datos para realizar la mayoría de las tareas de la práctica (entrenamiento, optimización de hiperparámetros, estimación de rendimiento futuro, etc.). "bank_competition " contiene datos cuyo propósito es simular una competición y, por lo tanto, no contiene la variable de respuesta ("deposit"). El modelo final se utilizará para hacer predicciones para el "bank_competition" dataset.

PASOS A SEGUIR

1. GITHUB (0,4 PUNTOS)

Para realizar la práctica, los estudiantes emplearán un **repositorio de código en GitHub**. Para ello, cada grupo debe crear un repositorio de código privado y agregar como «colaborador» al profesor de prácticas (que indicará a los estudiantes su nombre de usuario en GitHub). **Durante la primera semana, el grupo hará llegar al profesor de prácticas el enlace al repositorio de GitHub donde se harán los *commits*** (debe haber un único repositorio por grupo). **Se espera que cada grupo haga al menos un *commit* semanal del código de la práctica**. Además, también habrá que entregar el cuaderno (notebook) final a través de Aula Global.

2. EDA SIMPLIFICADO (0,3 PUNTOS)

Realice un **EDA simplificado**, principalmente para determinar cúantas variables e instancias hay, qué variables son categóricas/ordinales/numéricas, si hay variables categóricas con alta cardinalidad (>10 de valores únicos), qué variables tienen valores faltantes y cuántos, si hay columnas constantes o columnas de ID, y si se trata de un problema de regresión o clasificación. Si es esto último, ¿está desbalanceado? Para realizar esta parte se pide programar código que compruebe estas cuestiones (no basta una mera inspección visual).

Este EDA se utilizará como guía para cuando haya que llevar a cabo el preproceso de los datos.

Analizar particularmente la variable ***pdays***, y describir como se va a realizar el preproceso de esta variable (y llevar a cabo el preproceso ya en esta sección, si eso se considera correcto).

3. DECIDIR CÓMO SE VA A REALIZAR LA EVALUACIÓN (0,1 PUNTOS)

1. La estimación del rendimiento futuro (o evaluación *outer*) se realizará con **Holdout** (*train (2/3) / test (1/3)*). Se debe elegir una métrica adecuada para el problema, para ser utilizada a lo largo de la práctica.
2. Dividir los datos en *train* y *test*. Importante: la mayor parte de la práctica se llevará a cabo utilizando sólo *train*. La partición de *test* sólo se usará una vez que se haya decidido cúal es la mejor manera de obtener el modelo, sólo entonces se usará *test* para calcular la estimación de rendimiento/desempeño futuro.
3. Decide cómo se va a llevar a cabo la evaluación interna (*inner*). *Inner* se utiliza cuando se realiza la optimización de hiperparámetros (HPO), pero también se utiliza para evaluar y comparar diferentes alternativas. Por lo tanto, la mayor parte de la práctica utilizará la evaluación *inner*, excepto al final, donde se utilizará el conjunto de *test* (*outer*) para evaluar el modelo final.

4. MÉTODOS BÁSICOS: KNN Y TREES (1,0 PUNTOS)

1. Decidir, usando KNN el <u>método de escalado</u> más apropiado para este problema y usarlo de aquí en adelante cuando sea necesario. Se considerarán tres métodos de escalado (minmax, standard, robust).
2. A continuación, se considerarán estos <u>métodos</u>: KNN y árboles:
    a. Se evaluarán con sus hiperparámetros por omisión. También se medirán los tiempos que tarda el entrenamiento.
    b. Se usarán árboles poco profundos para obtener una interpretación sobre cómo se pueden llevar a cabo decisiones en este problema.
    c. Después, se ajustarán los hiperparámetros más importantes de cada método y se obtendrá su evaluación. Medir tiempos del entrenamiento, ahora con HPO.
    d. Se explicará mediante plots el efecto de los distintos valores de los hiper-parámetros en el resultado final (por ejemplo, en este problema, ¿los árboles necesitan de valores altos o bajos de *max_depth*? ¿qué ocurre con el número de vecinos en KNN?, etc.)
3. Obtener algunas conclusiones para esta sección, entre otras: ¿cuál es el mejor método? ¿A qué coste computacional? ¿Los resultados son mejores que los modelos triviales/naive/dummy? ¿El ajuste de hiperparámetros mejora con respecto a los valores por omisión? ¿Si hay mejora, es el coste computacional elevado?

5. MÉTODOS AVANZADOS: MODELOS LINEALES Y SVMS (0,6 PUNTOS)

En esta sección, se considerarán dos tipos de métodos: lineales (sin y con regularización L1) y SVMs:

1. Se evaluarán con sus hiperparámetros por omisión (medir tiempos).
2. Después, se ajustarán los hiperparámetros más importantes de cada método y se obtendrá su evaluación (medir también tiempos).
3. ¿Es posible extraer de alguna técnica qué atributos son más relevantes? ¿Cuáles son?.

4. RESULTADOS Y MODELO FINAL (0,3 PUNTOS)

1. Seleccionar la mejor alternativa de las evaluadas en los puntos anteriores (usando la evaluación *inner*).
2. Estimar el rendimiento / desempeño futuro del modelo (evaluación *outer* con el conjunto de test). Esta es una estimación de cómo se desempeñaría el modelo en la competición. Además de la métrica principal usada durante la práctica, se pide utilizar también en esta sección matrices de confusión.
3. Entrenar el modelo final. Guardarlo en un fichero (llamado «modelo_final.pkl»).
4. Utilizar el modelo final para obtener predicciones para el conjunto de datos de la competición. Guardar estas predicciones en un fichero (llamado «predicciones.csv»).

5. DESPLEGAR EL MODELO FINAL USANDO STREAMLIT (0,4 PUNTOS)

- Se trata de desplegar el modelo en producción, generando una aplicación web mediante Streamlit, que permita introducir valores para las variables de entrada para clientes nuevos, de tal manera que los gestores del banco puedan hacer predicciones para nuevos clientes.

6. TAREA DE ELECCIÓN ABIERTA (0,4 PUNTOS)

Decidir alguna tarea adicional, ya sea porque podría mejorar los resultados o porque te parece especialmente interesante. Justificar la elección**.**

¿QUÉ ENTREGAR?

- Código con dos notebooks (Recordar escribir los nombres de los miembros del equipo al principio de los notebooks):
    1. Uno que haga el EDA, ajuste de hiperparámetros, selección de modelo, etc. El notebook tiene que tener explicaciones de los procesos, análisis de los resultados, justificaciones de las decisiones, etc., preferiblemente usando tablas y gráficos.
    2. Otro que cargue el modelo final y lo use para hacer predicciones en los datos de la competición.
- El archivo conteniendo el modelo final (llamado «modelo_final.joblib») y el archivo conteniendo las predicciones en los datos de competición ("predicciones.csv").
- Código en un script en Python (*mystreamlit.py*) que haga el despliegue de vuestra pipeline mediante Streamlit. Se deberá demostrar que el despliegue funciona comparando las predicciones de vuestra pipeline en dos nuevas instancias, y las predicciones hechas por la app en Streamlit. Se deberá aportar un documento pdf con volcados de pantalla que demuestren que las predicciones son las mismas.
- El código y los archivos se entregarán en Aula Global en un .zip

- Se recuerda que además de la entrega final, cada semana hay que hacer al menos un commit en el GitHub privado de cada grupo (0.4 puntos).
- Si se decide usar IA generativa, se debe explicar brevemente en las celdas apropiadas del notebook para qué se usó y cómo (breve resumen).

APÉNDICE: DESCRIPCIÓN DE LAS VARIABLES

Variable	Short Description
age	Edad en años
job	Tipo de trabajo
marital	Estado marital
education	Nivel de educación
default	Algún crédito no devuelto?
balance	Balance anual medio
housing	¿Tiene una hipoteca?
loan	¿Tiene un préstamo?
contact	Tipo de contacto
day_of_week	Último día de contacto
month	Último mes de contacto
duration	Duración (segundos) del último contacto
campaign	Número de contactos durante esta campana y para este cliente
pdays	Número de días desde que este cliente fué contactacto en la campana anterior. -1 == sin contacto o desconocido
previous	Número de contactos antes de esta campana para este cliente
poutcome	Resultados de las campañas de marketing anteriores.
deposit	¿Contrató el cliente un depósito? VARIABLE DE RESPUESTA (TARGET, SALIDA)